Reconocimiento de dibujos de Quick, Draw! mediante redes neuronales convolucionales: comparación de dropout y aumento de datos

Sebastián Osorio Arteaga
Instituto Tecnológico de Estudios Superiores Monterrey
Querétaro, México
Email: sebastian.oso03@gmail.com

***Resumen*—**

I. Introducción

II. Descripción del dataset

Quick, Draw! reúne aproximadamente 50 millones de dibujos en 345 categorías y se distribuye bajo licencia Creative Commons Attribution 4.0 [1]. Se utilizan los archivos oficiales `numpy_bitmap`, que Google proporciona como imágenes en escala de grises de 28×28 píxeles, preprocesadas y centradas. Por ello, la preparación se concentra en seleccionar imágenes y comprobar sus características.

Las categorías del proyecto son gato, pez, bicicleta, avión, casa, árbol, reloj, paraguas, helado y estrella, codificadas de 0 a 9 en ese orden. Se seleccionan 5,000 dibujos por clase con semilla 42, para un total de 50,000. Este tamaño limita el costo de entrenamiento y mantiene una muestra balanceada; se eligió por razones prácticas y no como un tamaño óptimo demostrado.

III. Extracción, transformación y carga de los datos

III-A. Carga y limpieza

Los archivos originales se descargan una vez y se cargan con `np.load`. Se verifica que tengan tipo `uint8` y forma $(N, 784)$, donde cada fila contiene los píxeles de un dibujo. Después de seleccionar aleatoriamente hasta 5,000 imágenes por categoría, las filas se reorganizan a $(28, 28, 1)$.

La limpieza se aplica a la muestra: se descartan imágenes vacías y se utiliza `np.unique` para detectar duplicados exactos. Si una imagen aparece varias veces con la misma etiqueta, se conserva una copia; si tiene etiquetas diferentes, se excluye. Este control detecta copias idénticas, no dibujos visualmente parecidos.

En la muestra se encontraron 0 imágenes vacías, 0 repeticiones y 0 patrones con etiquetas distintas. Por ello se conservaron los 50,000 dibujos. Si alguna clase hubiera quedado con menos imágenes, las demás se habrían reducido a esa cantidad para mantener el balance.

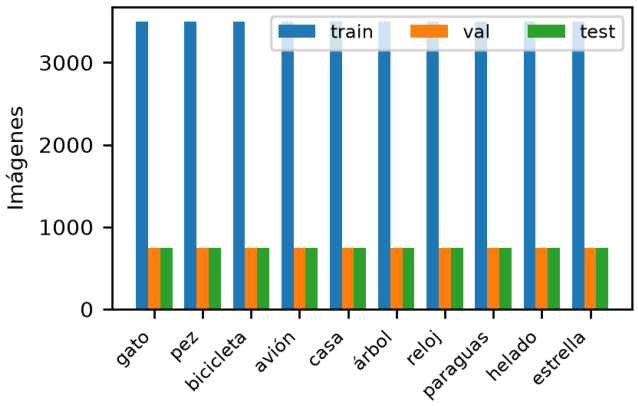


Figura 1. Cantidad de imágenes por clase en entrenamiento, validación y prueba.

III-B. Guardado de los datos

Las imágenes, etiquetas e índices de las particiones se guardan en un archivo `.npz`. Los cuatro modelos utilizan este mismo archivo para asegurar que se entrenen y comparen sobre los mismos ejemplos. Las imágenes permanecen como enteros entre 0 y 255 hasta entrar al modelo.

IV. Análisis exploratorio de los datos

El EDA revisa dimensiones, conteos, ejemplos e intensidades. Como Google ya entrega bitmaps con un formato uniforme, no se necesita una preparación extensa. La Fig. 1 muestra que las diez clases tienen la misma cantidad de ejemplos en cada partición.

Las imágenes tienen fondo negro y trazos claros, con intensidades de 0 a 255. Se conservan los tonos de gris. La Fig. 2 muestra dos dibujos de entrenamiento por clase: un mismo objeto puede representarse con distintas proporciones y niveles de detalle. Esta variabilidad motiva comparar regularización y aumento de datos.

V. Preparación de datos para el modelo

La división se realiza por clase: 70 % para entrenamiento, 15 % para validación y 15 % para prueba. Se comprueba que no existan imágenes idénticas compartidas entre conjuntos.

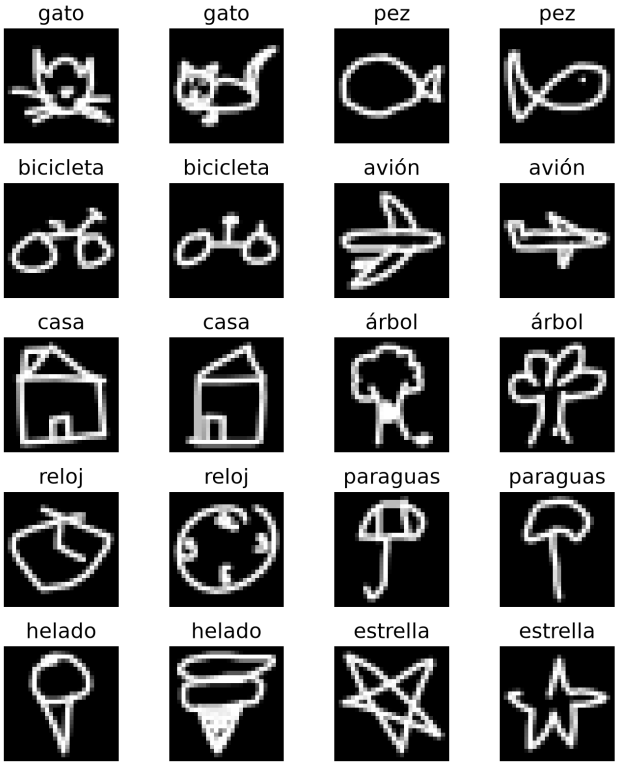


Figura 2. Dos ejemplos de entrenamiento por categoría, seleccionados con semilla fija.

Tabla I
DISTRIBUCIÓN DE LAS IMÁGENES.

Conjunto	Por clase	Total
Entrenamiento	3,500	35,000
Validación	750	7,500
Prueba	750	7,500

Entrenamiento ajusta los pesos, validación controla la parada y permite seleccionar el modelo, y prueba se reserva para evaluar al ganador. Separar selección y evaluación reduce el riesgo de ajustar las decisiones al conjunto de prueba [3].

La entrada del modelo es de $28 \times 28 \times 1$ y las etiquetas son enteros de 0 a 9. Una capa `Rescaling` divide los píxeles entre 255 para obtener valores entre 0 y 1. La normalización se mantiene dentro de la red para aplicar la misma transformación durante entrenamiento y predicción.

VI. CONSTRUCCIÓN Y ENTRENAMIENTO DE LA CNN

VI-A. Arquitectura

Se utiliza una CNN con dos bloques convolucionales y una capa densa. Las convoluciones aprenden patrones locales, como bordes y curvas; las capas densas combinan esa información para clasificar el dibujo. Este enfoque tiene antecedentes en el reconocimiento de imágenes manuscritas [2].

Morales y colaboradores incluyen un experimento con Quick, Draw! que utiliza imágenes de 28×28, convoluciones de 32 y 64 filtros de 3×3, ReLU, max-pooling y capas densas [4].

Tabla II
ARQUITECTURA COMPARTIDA POR LAS CUATRO VARIANTES.

Capa	Salida
Entrada y normalización	$28 \times 28 \times 1$
Aumento (opcional)	$28 \times 28 \times 1$
Conv2D, 32 filtros, 3×3, ReLU	$28 \times 28 \times 32$
MaxPooling, 2×2	$14 \times 14 \times 32$
Conv2D, 64 filtros, 3×3, ReLU	$14 \times 14 \times 64$
MaxPooling, 2×2	$7 \times 7 \times 64$
Flatten	3,136
Dense, ReLU	64
Dropout (opcional)	64
Dense, softmax	10

Este antecedente respalda utilizar componentes similares. En el proyecto se emplea una capa Dense de 64 unidades y una salida de diez clases; son adaptaciones propias, no una reproducción completa de aquella red.

Max-pooling reduce las dimensiones de la representación y Flatten la reorganiza como vector. La salida softmax produce una puntuación por clase; se elige la mayor. Las cuatro variantes mantienen 220,234 parámetros entrenables, lo que permite comparar los cambios de regularización sobre una misma arquitectura.

VI-B. Regularización mediante dropout

Dropout desactiva aleatoriamente parte de las unidades durante el entrenamiento para reducir la dependencia de activaciones particulares y ayudar a controlar el sobreajuste, siguiendo el método de Srivastava y colaboradores [5].

Se coloca después de Dense(64), con tasa 0.3: cada unidad tiene un 30 % de probabilidad de desactivarse durante el entrenamiento. Al realizar predicciones permanece desactivado [6]. Se compara su presencia o ausencia con esta tasa, sin buscar el mejor valor entre distintas alternativas.

VI-C. Aumento de datos

Se aplican rotaciones aleatorias de hasta $\pm 10^{\circ}$ y desplazamientos horizontales y verticales de hasta 10 %. Se eligieron cambios pequeños para variar la posición y orientación sin cambiar el objeto representado. Las transformaciones se aplican únicamente durante entrenamiento.

Simard y colaboradores estudian el uso de distorsiones en reconocimiento de documentos [7], y Zheng y colaboradores investigan aumentos específicos para dibujos [8]. Estos trabajos respaldan estudiar variaciones de entrada, aunque las amplitudes utilizadas aquí son decisiones del proyecto y no valores óptimos establecidos por esas referencias.

VI-D. Configuración del entrenamiento

Se utiliza entropía cruzada categórica con etiquetas enteras y Adam con tasa de aprendizaje 0.001, valor propuesto como configuración inicial por Kingma y Ba [9]. El tamaño de lote es 128 y el máximo es de 30 épocas.

La parada temprana supervisa la pérdida de validación y detiene el entrenamiento tras cinco épocas sin mejora, siguiendo el principio de controlar el ajuste mediante validación [10].

Tabla III
ÉPOCAS REALIZADAS Y MEJOR ÉPOCA SEGÚN PÉRDIDA DE VALIDACIÓN.

Variante	Realizadas	Mejor época
Base	12	7
Dropout	13	8
Aumento	24	19
Combinado	29	24

Se guarda el modelo con menor pérdida y un CSV con las métricas de cada época. El tamaño de lote, la paciencia y el máximo de épocas son elecciones prácticas del proyecto.

VII. EXPERIMENTOS Y COMPARACIÓN DE VARIANTES

VII-A. Configuraciones

Se entrenan cuatro modelos independientes desde cero: **base**, sin regularización adicional; **dropout**, con tasa 0.3; **aumento**, con rotaciones y desplazamientos; y **combinado**, con ambas técnicas. Comparten datos, arquitectura, optimizador y reglas de parada. Combinado es una red entrenada por separado, no una combinación de predicciones de las otras tres.

VII-B. Resultados de validación

Se comparan los mejores modelos guardados sobre los mismos 7,500 dibujos de validación. La Tabla IV presenta pérdida, accuracy y métricas macro, que promedian el resultado de las diez clases.

Combinado obtiene la menor pérdida de validación, 0.184986, y se selecciona como modelo final. Alcanza 95.57 % de accuracy, frente a 95.37 % de aumento, 94.19 % de dropout y 93.85 % de base. La ventaja frente a aumento es de 15 aciertos; con una sola ejecución por variante no puede afirmarse una superioridad estadística.

La selección se realiza por pérdida porque considera también las puntuaciones asignadas a las respuestas, mientras que accuracy solo cuenta las clases acertadas. El modelo final conserva los pesos del ganador, sin un entrenamiento adicional.

VII-C. Curvas de aprendizaje

La Fig. 3 muestran la evolución de pérdida y accuracy. En base, la pérdida de entrenamiento continúa disminuyendo mientras la de validación deja de mejorar, comportamiento compatible con sobreajuste. La parada temprana permite conservar el mejor punto de validación.

Dropout y aumento dificultan el entrenamiento al desactivar unidades o transformar las entradas. Ambos se desactivan al evaluar validación y prueba. Por ello, una accuracy de validación mayor que la de entrenamiento durante una época puede deberse a estas condiciones distintas. En este experimento, aumento y combinado alcanzan mejores resultados de validación que base.

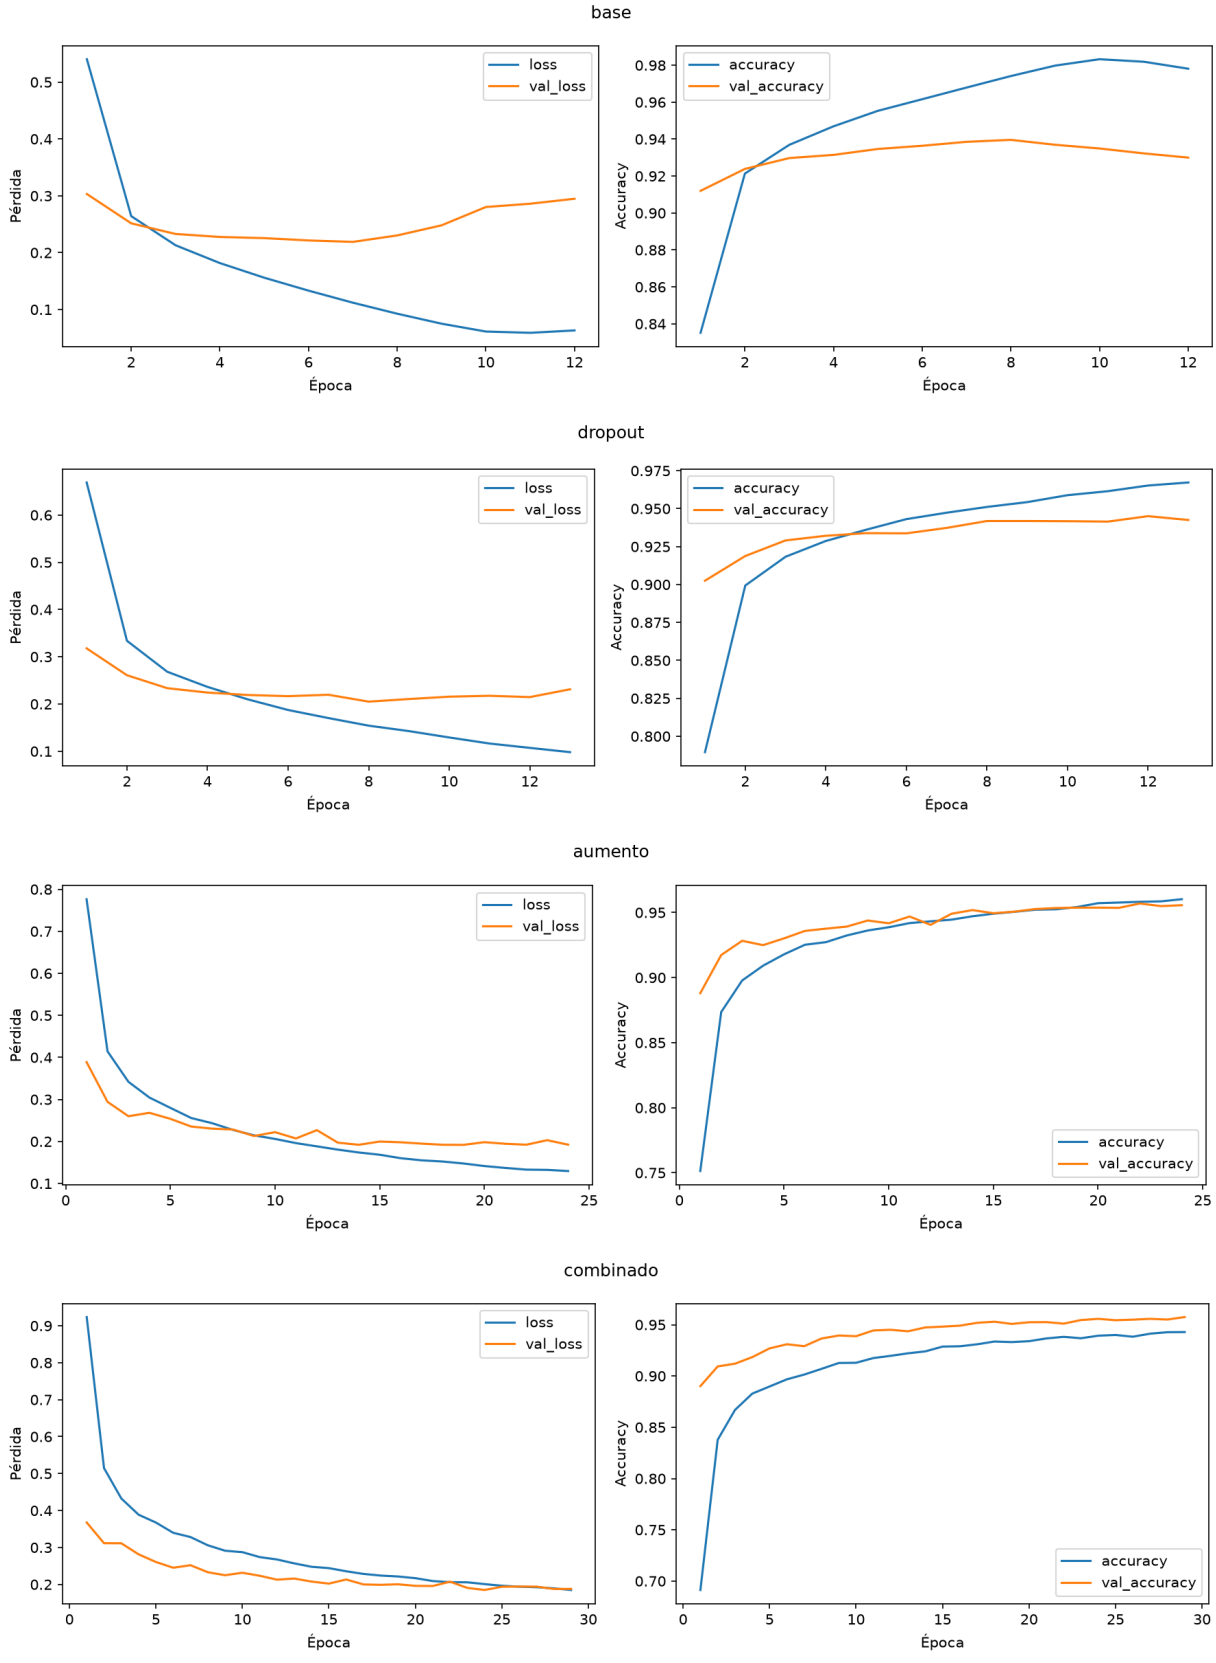


Figura 3. Curvas de aprendizaje: base, dropout, aumento y combinado, de arriba abajo.

Tabla IV
COMPARACIÓN EN VALIDACIÓN. PRECISIÓN, RECALL Y F1 SON PROMEDIOS MACRO.

Variante	Pérdida	Accuracy (%)	Precisión	Recall	F1
Base	0.218954	93.8533	0.939284	0.938533	0.938526
Dropout	0.205066	94.1867	0.942083	0.941867	0.941855
Aumento	0.191920	95.3733	0.954131	0.953733	0.953766
Combinado	0.184986	95.5733	0.955975	0.955733	0.955744

VIII. EVALUACIÓN DEL MODELO FINAL

Después de seleccionar combinado se evalúa en los 7,500 dibujos de prueba. Obtiene pérdida 0.168923, accuracy **95.68 %**, precisión macro 0.9572, recall macro 0.9568 y F1 macro **0.9569**. Esto corresponde a 7,176 aciertos y 324 errores.

La matriz de confusión (Fig. 4) permite identificar errores por categoría. Entre ellos aparecen 24 dibujos de avión clasificados como estrella y 18 de estrella clasificados como avión. Estas confusiones sugieren revisar semejanzas entre trazos, sin asumir una causa única para todos los errores.

La Fig. 5 muestra casos que el modelo clasificó incorrectamente con puntuaciones altas. Algunos dibujos tienen pocos trazos o formas ambiguas. Una puntuación alta no garantiza una respuesta correcta; estos ejemplos tampoco representan la frecuencia de todos los tipos de error.

Los resultados se limitan a diez categorías y a una ejecución por variante. No se evaluó el reconocimiento de clases desconocidas ni se repitieron entrenamientos con distintas semillas. La comparación permite describir el comportamiento observado, sin establecer que esta configuración sea óptima para todo Quick, Draw!.

REFERENCIAS

[1] Google Creative Lab, "The Quick, Draw! Dataset," documentación y licencia de los datos. [En línea]. Disponible: https://github.com/googlecreativelab/quickdraw-dataset. Consultado: 3 de noviembre de 2026.

[2] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, núm. 11, pp. 2278–2324, 1998. https://bottou.org/papers/lecun-98h.

[3] G. C. Cawley y N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *JMLR*, vol. 11, pp. 2079–2107, 2010. https://jmlr.org/papers/v11/cawley10a.html.

[4] A. Morales, J. Fierrez, A. Acien, R. Tolosana e I. Serna, "SetMargin loss applied to deep keystroke biometrics with circle packing interpretation," *Pattern Recognition*, vol. 122, art. 108283, 2022. https://doi.org/10.1016/j.patcog.2021.108283.

[5] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *JMLR*, vol. 15, pp. 1929–1958, 2014. https://jmlr.org/papers/v15/srivastava14a.html.

[6] Keras, "Dropout layer," documentación de implementación. [En línea]. Disponible: https://keras.io/api/layers/regularization_layers/dropout/. Consultado: 3 de noviembre de 2026.

[7] P. Y. Simard, D. Steinkraus y J. C. Platt, "Best practices for convolutional neural networks applied to visual document analysis," en *ICDAR*, pp. 958–963, 2003. https://www.microsoft.com/en-us/research/publication/best-practices-for-convolutional-neural-networks-applied-to-visual-document-analysis/.

[8] Y. Zheng, H. Yao, X. Sun, S. Zhang, S. Zhao y F. Porikli, "Sketch-specific data augmentation for freehand sketch recognition," arXiv:1910.06038, 2019. https://arxiv.org/abs/1910.06038.

[9] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," *ICLR*, 2015; arXiv:1412.6980. https://arxiv.org/abs/1412.6980.

[10] L. Prechelt, "Early stopping—but when?," en *Neural Networks: Tricks of the Trade*, LNCS 1524, pp. 55–69, 1998. Manuscrito del autor: https://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf.

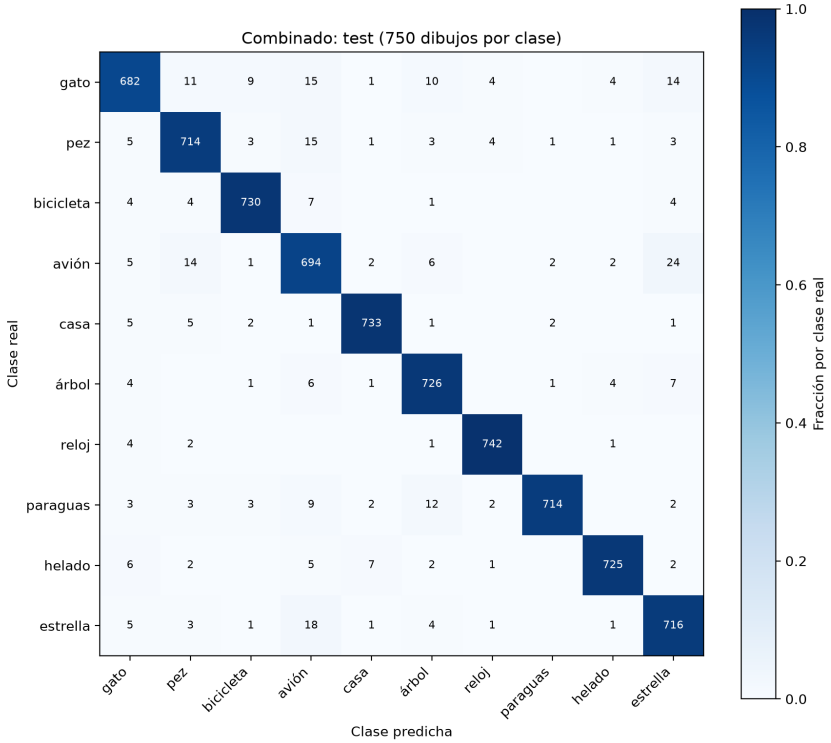


Figura 4. Matriz de confusión de combinado en prueba. Las filas son etiquetas reales y las columnas, predicciones; cada clase tiene 750 imágenes.

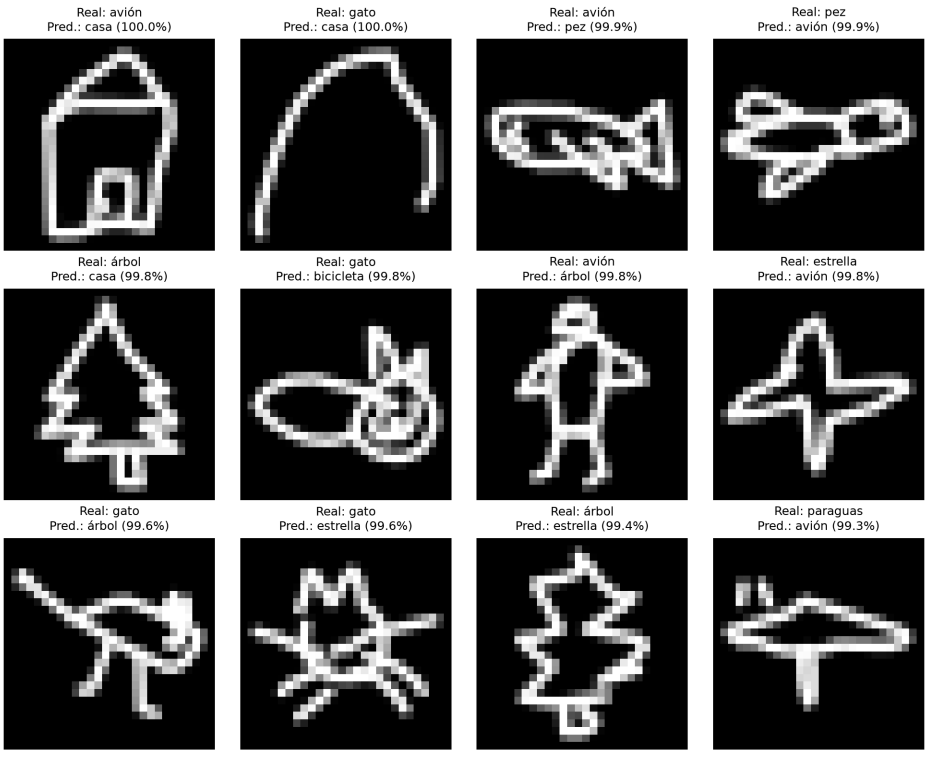


Figura 5. Doce errores de prueba con mayor puntuación de la clase predicha. “Real” corresponde a la etiqueta del dataset.